汶川震后泥石流多时相数据集的流程复现与降雨阈值/易发性建模

复现对象：Wang, Chang, Le, Xiang & Ni (2022), Scientific Data 9:525

RainGaugeNet 复现项目

2026-09-26

1. 摘要与核心结论

本文对数据论文 **Wang, L., Chang, M., Le, J., Xiang, L. & Ni, Z. (2022).** *Two multi-temporal datasets to track debris flow after the 2008 Wenchuan earthquake.* **Scientific Data 9:525**（doi:10.1038/s41597-022-01658-y， 数据 doi:10.5281/zenodo.6891244） 所发布的龙门山震中区数据，完成了**从原始数据到降雨阈值与易发性分类的完整流程复现。**

> **必须先说清楚复现的性质。** 该论文是 **Data Descriptor（数据论文）**，正文不含任何降雨阈值拟合或易发性建模， 也没有报告任何 I–D 曲线系数。因此本文**不是**对原文数值的复刻，而是 **用论文发布的数据完成它自己建议的应用**——原文摘要写明这批数据 *“can aid different applications, including the early warning and engineering prevention of post-earthquake debris flow”*。原文可供核验的对象只有两套数据本身（事件、降雨、坝体）， 本文对它们的复现性做了独立校验（见 C1）；所有模型与阈值结果都是**本项目的实验结论。**

核心结论

C1｜数据可复现，规模与原文自洽。 清洗后得到 **186 条泥石流事件**、**79 个流域**、 **465 个逐小时降雨文件**，事件跨 **2008–2020 年**，与原文声明的 *“186 debris flows affecting 79 watersheds”* 完全一致。本文用鞋带公式独立重算的流域面积合计 **851.0 km²**，原文声明研究区 **892 km²**，相对偏差 **−4.6%**（差值是原文研究区边界与 79 个流域多边形之和的口径差异，不是错误）。 流域多边形面积与 `.dbf` 属性 `Area` 的最大相对误差 **2.5×10^{-6}**，79 行中超过 1% 的有 **0** 行。

C2｜降雨确实能区分触发 / 非触发，且信号主要来自”雨量”与”历时”，不是”短时雨强”。 在 1597 行（444 正 / 1153 负，正例率 27.8%）的雨场级数据集上，主协议 `GroupKFold`（按事件 `DF_ID` 分组，杜绝同一次事件跨折泄漏）下随机森林达到 **accuracy 0.9562 / precision 0.9329 / recall 0.9077 / F1 0.9201 / ROC-AUC 0.9832**。 随机划分协议只把 accuracy 抬到 0.9625（**仅高 0.63 个百分点**），说明 “一次事件多个雨量站”带来的乐观偏差在本数据上**存在但有限**。 特征重要性显示前两位是 `n_wet_hours` **(0.174)**、`duration_h` **(0.172)**， 第 3–5 位是 `max_24h` (0.090)、`max_72h` (0.072)、`total_mm` (0.068)； 而单小时峰值 `max_1h` **仅 0.022（排第 14/16）——降雨持续时长与长窗口累计量 比短时强降雨更能判别触发。**分布侧同向：触发场 `total_mm` 中位数 49.1 mm vs 非触发场 9.0 mm（差 5.5 倍），而 `mean_intensity` 只差 2.62 vs 2.15 mm/h（差 1.2 倍）。

C3｜经验 I–D 阈值显著弱于机器学习，且"高召回"与"高精度"不可兼得。 六条经验曲线在同一批 1597 行、同一批标签上评分：准确率最高的是 `quantile_p90_trigger`（`I = 47.35·D^(-0.5535)`）accuracy **0.7733**、precision **0.9271**，但 recall 只有 **0.2005**—— **漏报 80% 的触发场**，作为预警阈值不可用；反过来 `ols_all_points`（`I = 8.416·D^(-0.8011)`）recall **0.9369** 但 precision 仅 **0.4361**， 意味着**报 10 次警有 5.6 次是空的**。经验曲线里 F1 最高只有 **0.6055**， 随机森林是 **0.9201**，差距 **0.31**。

C4｜I–D 幂律只在"分位数包络"上成立，在原始点云上并不成立。 这是本次复现最重要的方法学发现。 对全部 11179 个 (D, I) 窗口点直接做 OLS，**r^2 = 0.3503**；只用触发点做 OLS，**r^2 = 0.4855**—— 即原始点云只能被幂律解释 **35%–49%** 的 log–log 方差。 而改为"对每个固定窗长先取分位数、再对分位数点拟合幂律"，r^2 立刻升到 **0.9649–0.9911**。这说明：文献里 I–D 幂律的成立**依赖于先按 D 分箱再取包络**， 把所有点直接丢进最小二乘会得到一条 r^2 只有 0.35 的"假幂律"。 本项目因此**并列报告两类拟合**，而不是只报好看的那条。

C5｜易发性可预测，但信号弱、方差大。 79 个流域的 RepeatedStratifiedKFold （5 折 × 10 次）结果显示，逻辑回归准确率最高（**0.7598 ± 0.0970，F1 0.7307 ± 0.1079**）， XGBoost 的 ROC-AUC 最高（**0.8186**）。标准差约 **0.08–0.11**， 而模型间 accuracy 差距（0.7115–0.7598）**小于一个标准差**， 因此**不应据此给模型排序**。

C6｜工程防治与事件数之间存在明显的选址偏差，本数据无法评估坝的效果。 无坝流域（56 个）平均 **1.88** 次事件；有坝流域平均 **2.55–3.00** 次 （1 坝 2.78、2 坝 3.00、≥3 坝 2.55）——**坝恰恰建在灾害更频发的地方**。 同向证据： `corr(area, has_dam) = 0.5133`（大流域更可能有坝）， 而 `corr(area, n_events) = -0.0175`（面积与事件数几乎无关）。 在这种横截面数据上，任何"有坝 → 事件更多/更少"的推断都**不成立**。

C7｜跨期泛化不可评估。 `temporal` 协议（训练 ≤2013 共 1540 行，测试 ≥2016 仅 **57 行**） 给出的指标在模型间剧烈摆动：随机森林 accuracy **0.8947**，逻辑回归 **0.9825**。 57 行测试集不足以支撑任何关于"阈值随震后恢复"的结论，本文**明确不采信**该协议的数字。

---

2. 数据描述

2.1 来源与获取

项目	内容
论文	Scientific Data 9:525（2022-08-27 在线）
数据 DOI	10.5281/zenodo.6891244
许可	CC BY 4.0
研究区	龙门山断裂带震中区（汶川县及邻区），约 892 km²
时间跨度	2008–2020

原始数据**不由本仓库分发**，需从 Zenodo 下载后放至 `data/raw/`（目录约定见 `README.md` §3）。

2.2 两套数据集的结构

数据集 1：泥石流事件与触发降雨

文件	类型	关键字段
`Dataset1_Debris flow.csv`	表	`DF_ID`, `Gully name`, `Latitude`, `Longitude`, `Year/Month/Day`, `Time(24 hour)`, `Deposition volume (m3)`, `Reference of Data source`
`Debris_flow_catchment.shp/.dbf`	79 个流域多边形	`Name`, `CID`, `County`, `Area`
`ID_RG_DF_<DF_ID>/*.txt`	465 个逐小时降雨序列	文件名 `<seq>_<rg_id>_<YYYYMMDDHH>`；正文两列 `YYYYMMDDHH` + 雨量(mm)

每个 `ID_RG_DF_<DF_ID>/` 文件夹存放**该事件 8 km 范围内的所有雨量站**、在 **事件前 7 天至事件后 1 天**窗口内的逐小时序列（依据官方 `Read me` 说明）。

数据集 2：工程防治措施（拦砂坝）

文件	关键字段
`Dataset2_Dam.csv`	`Name`, `C_ID`, `Dam number`, `Built Time`, `Successful prevention and control`
`Dataset2_damdata.shp` 等	坝体点位（`Dam_ID`, `C_ID`, 坐标）

2.3 数据规模实测

指标	数值
泥石流事件数	186
流域多边形数	79
降雨序列文件数	465
含降雨数据的事件文件夹数	147
降雨文件中出现的雨量站编号数	39
拦砂坝总数	55（分布在 23 个流域）
无坝流域数	56
零事件流域数	12
流域面积中位数	5.59 km²（最大 54.73 km²）
流域面积合计	851.0 km²

逐年事件数（合计 186）：

年份	2008	2009	2010	2011	2012	2013	2016	2019	2020
事件数	29	6	**98**	22	1	16	1	12	1

2014、2015、2017、2018 四年**没有事件记录**。2010 年占全部事件的 **52.7%**（98/186），对应 “8·13” 群发泥石流；2013 年（16 次）对应 “7·10”；2019 年（12 次）对应 “8·20”。**事件在时间上高度集中**，这一点直接决定了后文交叉验证协议的选择。

---

3. 数据清洗

清洗层实现在 `src/wenchuan/clean.py`，产出三张中间表到 `data/interim/`。过程中有三个**会改变结论**的问题必须显式处理，下面逐条记录。

3.1 坐标列名与内容是反的

`Dataset1_Debris flow.csv` 中名为 `Latitude` 的列实际存放 **103.x（经度）**，名为 `Longitude` 的列实际存放 **31.x（纬度）**。龙门山震中区不可能有纬度 103°。

处理：`io.load_events()` 把两列重命名为真值 `lon` / `lat`，原始列另存为 `Latitude_raw` / `Longitude_raw` 以便追溯。清洗后形心经度范围 **103.3258–103.6323**、纬度 **30.9894–31.4772**，与该区域真实位置吻合。**若不修正，所有空间归属都会落到地球另一侧。**

3.2 95/186 条事件没有时刻

`Time(24 hour)` 字段为 `-`。这些事件的 `datetime` 用当天 00:00 兜底，并置 `time_missing = True`（共 **95** 条）。因此降雨触发判定以**整个日历日**为窗口（`features.label_triggers`），而不是拿 12:00 当精确时刻。这也是 `trigger_overlap_h == 0`（当天无雨、退化为”取当天前最后一场雨”）的 **7 / 444** 行正样本的来源，该退化比例可接受且已量化。

3.3 事件名与流域名是两种写法

事件表存**单个沟名**（如 `Mayangdian`），流域表存 **`/` 连接的多沟名**（如 `Douyaping/Mayangdian/Maliuwan/Qingling/Guanshan` → `W16`）。

处理：`clean.build_catchment_lookup()` 把流域名拆成子名建立索引，再做**最长匹配**兜底；名称仍无法匹配时，`catchment_assign.py` 用 **点-多边形空间关系**兜底，并记录 `catchment_source ∈ {name, geometry, unassigned}`。最终 **167 / 186（89.8%）** 条事件获得了 `C_ID`。

3.4 其它清洗动作

- 表头 BOM 与前后空白统一去除（`encoding="utf-8-sig"`）。
- 降雨序列排序、按小时去重求和；抽样 60 个文件诊断：**最大缺失小时数 0**，时间步长唯一值为 **1.0 h**——序列完整且严格等间隔。
- `Built Time` 支持 `2013` 与 `2011-2013` 两种写法，后者取首年。
- `Successful prevention and control` 归一化为布尔 `prevented`，并保留 `prevention_known` 区分”明确为否”与”未记录”。

---

4. 特征工程

4.1 降雨场次切分

窗口内远不止一场雨，因此它**天然提供了非触发场次作为负样本**， 不需要合成负样本。一场”雨”的定义（常量集中在 `features.py` 顶部）：

常量	值	含义
`WET_MM`	0.1	小时雨量 ≥ 该值算”湿小时”
`DRY_GAP_H`	6	连续干小时 > 6 h 才切成两场
`MIN_TOTAL_MM`	1.0	场次总雨量 < 1 mm 丢弃
`API_K`	0.9	前期降水指数的小时衰减系数

4.2 降雨特征（16 个）

`duration_h`, `n_wet_hours`, `total_mm`, `max_1h`, `max_3h`, `max_6h`, `max_12h`, `max_24h`, `max_48h`, `max_72h`, `mean_intensity`, `peak_intensity`, `antecedent_24h`, `antecedent_72h`, `antecedent_168h`, `api`

触发场 vs 非触发场的分布差异（中位数）：

特征	触发场 (n=444)	非触发场 (n=1153)	倍数
`total_mm`	49.10	9.00	5.5×
`n_wet_hours`	19.0	5.0	3.8×
`duration_h`	20.0	8.0	2.5×
`max_24h` (mm)	44.80	9.00	5.0×
`max_1h` (mm)	15.90	4.90	3.2×
`antecedent_24h` (mm)	29.40	0.00	—
`api`	5.06	0.07	72×
`mean_intensity` (mm/h)	2.62	2.15	**1.2×**

注意最后一行：`mean_intensity` 两组的差距（2.62 vs 2.15）**远小于** `total_mm`（49.1 vs 9.0）—— **这是 C2 结论的分布侧证据：区分能力主要在”下了多少、下了多久”，而不是”下得多急”。**

4.3 流域特征（13 个）

形态类：`area_km2`, `poly_perimeter_km`, `compactness = 4πA/P²`, `bbox_width_km`, `bbox_height_km`, `bbox_aspect`, `centroid_lon`, `centroid_lat`, `n_gullies` 防治类：`dam_number`, `has_dam`, `built_year`, `has_built_year`

> **不造数据。** 数据集**不含 DEM**，因此**不虚构坡度或高程特征**（`catchment_geom.py` 顶部明确声明）。流域形态特征由手写 SHP 读取器计算， 多边形坐标位于 WGS84 / UTM 48N，面积为米制。

5. 任务 A：降雨阈值分类

5.1 样本构造

- **一行 = 一个（雨量站文件, 雨场）对。**
- **正样本**：与泥石流发生日重叠的雨场。
- **负样本**：同一文件夹窗口内的其它雨场（来自数据自身，非合成）。
- 结果：**1597 行 / 444 正 / 1153 负，正例率 27.8%**； 行来自 **146** 个事件文件夹（其中 **144** 个含至少一个被标注的触发场），涉及 **39** 个雨量站。

5.2 关键问题：行与行不独立

一次泥石流事件贡献**多个**雨量站文件，它的触发雨场在多个站上被**重复计入**。 随机划分会把同一场雨同时放进训练和测试，构成**泄漏**。 因此本文**同时报告三种协议**，把泄漏造成的乐观偏差**量化出来**而不是藏起来：

协议	划分方式	作用
`random`	分层随机 7:3	有泄漏，**仅作乐观上界**，不作为结论
`group_event`	`GroupKFold`，以 `DF_ID` 分组	**主协议**，同一次事件不跨折
`temporal`	训练 ≤2013，测试 ≥2016	检验跨期泛化

5.3 结果

协议 `group_event`（主协议）

模型	accuracy	precision	recall	F1	ROC-AUC
logistic_regression	0.9036	0.8059	0.8604	0.8322	0.9225
random_forest	**0.9562**	**0.9329**	**0.9077**	**0.9201**	**0.9832**
svm_rbf	0.9180	0.8323	0.8829	0.8568	0.9340
gradient_boosting	0.9555	0.9388	0.8986	0.9183	0.9735
xgboost	0.9580	0.9415	0.9054	0.9231	0.9802

随机森林混淆矩阵 `[[1124, 29], [41, 403]]`：**1124** 个真负、**29** 个假正、 **41** 个假负、**403** 个真正。假负（漏报触发场）41 个，是预警场景中最需要关注的错误类型。

协议 `random`（有泄漏，仅作对照）

模型	accuracy	precision	recall	F1	ROC-AUC
logistic_regression	0.9125	0.8182	0.8797	0.8478	0.9214
random_forest	0.9625	0.9389	0.9248	0.9318	0.9876
svm_rbf	0.9250	0.8593	0.8722	0.8657	0.9224
gradient_boosting	0.9583	0.9313	0.9173	0.9242	0.9785
xgboost	0.9646	0.9462	0.9248	0.9354	0.9890

泄漏代价：随机森林 accuracy 从 0.9562 → 0.9625（**+0.63 pp**）， F1 从 0.9201 → 0.9318（**+1.17 pp**）。**偏差存在但不大。** 这个量化的”+0.6 ~ 1.2 pp”本身就是本次复现的一个有用产出： 说明在这批数据上，**按事件分组的严谨协议并不会让结论崩塌**， 但也提醒同类研究不应只报随机划分的数字。

协议 `temporal`（不采信）

训练 ≤2013（1540 行） / 测试 ≥2016（**57 行**，含 2016、2019、2020）。

模型	accuracy	precision	recall	F1	ROC-AUC
logistic_regression	0.9825	0.9583	1.0000	0.9787	0.9949
random_forest	0.8947	1.0000	0.7391	0.8500	0.9987
svm_rbf	0.9825	0.9583	1.0000	0.9787	0.9987
gradient_boosting	0.8772	1.0000	0.6957	0.8205	0.9859
xgboost	0.8772	1.0000	0.6957	0.8205	0.9923

ROC-AUC 全部 ≥0.986 而 accuracy 在 0.877–0.983 间乱跳， 是**小测试集 + 阈值敏感**的典型表现（57 行里 23 个正例，1 个样本 ≈ 1.8 pp）。 该协议**只能说明”模型学到了可跨期的信号”，不能给出任何性能估计**，更不能据此论证阈值随震后恢复。

5.4 特征重要性（Task A，随机森林杂质重要性，全部 16 项）

排名	特征	重要性	排名	特征	重要性
1	`n_wet_hours`	**0.1739**	9	`antecedent_72h`	0.0522
2	`duration_h`	**0.1715**	10	`antecedent_24h`	0.0406
3	`max_24h`	0.0899	11	`max_12h`	0.0336
4	`max_72h`	0.0723	12	`max_3h`	0.0258
5	`total_mm`	0.0681	13	`peak_intensity`	0.0226
6	`api`	0.0643	14	`max_1h`	**0.0217**
7	`antecedent_168h`	0.0621	15	`mean_intensity`	0.0217
8	`max_48h`	0.0611	16	`max_6h`	0.0184

前两位全是”时长”类特征（湿小时数、降雨历时），单小时峰值 `max_1h` 排到第 14。 这与 4.2 节的分布观察一致。对预警实践的含义： **盯着降雨持续时间和累计雨量，比盯短时强降雨更有效**（在这批数据上）。

---

6. 经验 I–D 阈值与对比

6.1 方法学要点：为什么必须用固定时间窗

经典形式为 `I = a·D^(-b)`（Caine 1980 的幂律形式）。 本文**第一版实现按”湿 spell 长度”取 D**，效果明显更差：

- 湿 spell 中位数 **20 h**、最长 **82 h**——因为 6 h 干间隔把连续季风降雨合并了；
- 由此得到的 (D, I) 点云 log–log Pearson r 只有 **0.274**， 且 OLS 斜率被少数极端长历时样本主导，**不能刻画物理包络**。

> 早期草稿的 `threshold.py` 文档字符串曾写这里”几乎零相关（r ≈ −0.08） “。 **本次复算不成立**：实际 Pearson r = **+0.274**（n = 1597）。 该注释与 `make_figures.py` 图 1 标题里的”r = 0.01” 均已按实测值更正， 更正记录见 §10.6。**报告只引用可复算的数字。**

修正：改为对每个固定窗长 D，取**任意 D 小时窗口内的最大雨量**，`I(D) = P_max(D)/D`。 窗长集合为 **1, 3, 6, 12, 24, 48, 72 h**，每个雨场贡献 7 个点， 共构造 **11179** 个 (D, I) 对。

6.2 六条经验曲线及评分

全部曲线在**同一批 1597 行、同一批标签**上与 ML 模型同口径评分 （判定规则： `I_obs(D) > I_thr(D)` 即预报触发）。

名称	方程	拟合 r^2	accuracy	precision	recall	F1
`ols_all_points`	`I = 8.416·D^(-0.8011)`	0.3503	0.6456	0.4361	**0.9369**	0.5951
`ols_trigger_only`	`I = 17.72·D^(-0.6521)`	0.4855	0.6807	0.4446	0.5968	0.5096
`ols_trigger_minus_1sd`	`I = 6.829·D^(-0.6521)`	0.4855	0.6606	0.4473	**0.9369**	**0.6055**
`quantile_p50_trigger`	`I = 18.47·D^(-0.7397)`	**0.9909**	0.7120	0.4881	0.7365	0.5871
`quantile_p90_trigger`	`I = 47.35·D^(-0.5535)`	0.9649	**0.7733**	**0.9271**	0.2005	0.3296
`quantile_p90_all`	`I = 43.81·D^(-0.742)`	**0.9911**	0.7558	0.6154	0.3243	0.4248

6.3 两个必须讲清楚的发现

发现一：原始 (D, I) 点云只能被幂律解释 35%–49%。 OLS 三行的 r^2 分别是 **0.3503 / 0.4855 / 0.4855**。也就是说，把 11179 个点直接丢进最小二乘，得到的直线只解释约三分之一到一半的方差； 那条 `I = 8.416·D^(-0.8011)` 的幂律**形式对、参数不可靠**。 文献中 I–D 幂律之所以拟合得很好，是因为**先按 D 分箱、再取分位数/包络**—— 本文的 `quantile_p50_trigger` 与 `quantile_p90_all` 因此拿到 **r^2 = 0.9909 / 0.9911**。 **把 “OLS 全点” 和 “分位数包络” 混为一谈，是这类复现里最常见的错误。** 本项目因此把两类结果并列报告。

发现二：阈值曲线的精度 / 召回权衡极其陡峭。 `quantile_p90_trigger`（`I = 47.35·D^(-0.5535)`）是准确率最高的经验曲线（0.7733）， precision 高达 0.9271（1153 个负样本里只误报 7 个）， 但 recall 只有 **0.2005**——它把阈值抬得很高，代价是**漏掉 444 个触发场中的 355 个**， 作为预警阈值**不可用**。反过来，把线压低（`ols_all_points`、`ols_trigger_minus_1sd`） 能把 recall 拉到 0.9369（444 个只漏 28 个），但 precision 掉到 0.436–0.447， **每报 10 次警有 5.5 次以上是空的**。

与机器学习的差距：经验曲线里 F1 最高的是 0.6055，随机森林是 **0.9201**， 差距 **0.31**。原因是经验阈值只用 `(D, I)` 两个量， 而随机森林同时用了历时、湿小时数、多窗长雨量、前期雨量、API 等 16 个特征。 **这个差距本身说明：单靠 I–D 曲线做这批数据的预警，还有很大提升空间。**

6.4 机器学习等效阈值：诊断失败，如实报告

`threshold.fit_ml_equivalent_threshold()` 试图从随机森林的 0.5 概率等高线 反推一条可直接使用的 I–D 曲线（做法：对每个窗长 D，构造合成雨场并扫描峰值深度， 取预测概率首次 ≥0.5 的深度）。

结果：`ml_equivalent_threshold` 返回空字典 `{}`，诊断失败。 原因是合成样本只有一个特征列被赋值，其余 15 个特征被填 0， 模型在这些” 物理上不可能” 的输入（例如 24 h 窗口下雨量 300 mm 但历时 `duration_h` =0）上 概率曲线不单调，无法稳定地找到 0.5 穿越点。

本文**如实记录该失败**，而不是换一套参数把它” 调出” 一条好看的曲线。 这也提示：**把树模型的决策面反解成单条幂律曲线，在这类多特征问题上并不可靠**； 若要做 ML 阈值，更稳妥的路线是直接输出概率（如 §5.3）而非反解曲线。

---

7. 任务 B：流域易发性分类

7.1 样本与标签

- **一行 = 一个流域**，共 **79 行**。
- **标签**： `susceptible = (n_events > median(n_events))`，中位数 = **1.0**， 因此正类 **35** 个（事件数 ≥2），负类 **44** 个（事件数 ≤1）。
- **防泄漏**： 显式排除事件派生列 `n_events`， `first_event`， `last_event`， `total_volume_m3`， `event_span_years`——它们直接由标签算出，留下就是自欺。 模型只用 **13** 个形态 + 防治特征。

7.2 结果（RepeatedStratifiedKFold，5 折 × 10 次重复）

模型	accuracy	precision	recall	F1	ROC-AUC
logistic_regression	**0.7598 ± 0.0970**	**0.7543**	**0.7429**	**0.7307 ± 0.1079**	0.8082
random_forest	0.7277 ± 0.0847	0.6920	0.7457	0.7001 ± 0.1125	0.7951
svm_rbf	0.7115 ± 0.1129	0.6833	0.7057	0.6738 ± 0.1504	0.7822
gradient_boosting	0.7140 ± 0.1091	0.7043	0.6800	0.6737 ± 0.1262	0.7992
xgboost	0.7326 ± 0.0803	0.7101	0.7029	0.6927 ± 0.1070	**0.8186**

读法：标准差 ≈ 0.08–0.11，模型间 accuracy 差距（0.7115–0.7598）**小于一个标准差**。 因此**不能声称"逻辑回归优于随机森林"**，只能说"在这个标签定义下， 形态 + 防治特征能提供约 **0.78–0.82** 的 ROC-AUC 排序能力，且不稳定"。

5 折 OOF 混淆矩阵（一次性留出，便于看错误结构）：

- 随机森林：acc 0.7468 / F1 0.7222，CM `[[33, 11], [9, 26]]`
- 逻辑回归：acc 0.7342 / F1 0.6957，CM `[[34, 10], [11, 24]]`

7.3 特征重要性

特征	RF 重要性	逻辑回归系数
`centroid_lat`	**0.1543**	−0.5265
`n_gullies`	0.1272	**+1.9491**
`poly_perimeter_km`	0.1127	+0.4610
`bbox_height_km`	0.1109	−0.1581
`area_km2`	0.0955	+0.2082
`compactness`	0.0885	+0.6170
`centroid_lon`	0.0860	−0.3197
`bbox_aspect`	0.0787	−0.1313
`bbox_width_km`	0.0740	+0.2866
`dam_number`	0.0366	+0.4310
`has_dam`	0.0155	+0.1326
`has_built_year`	0.0144	+0.1331
`built_year`	0.0058	+0.1418

地理位置（`centroid_lat` / `centroid_lon`）和流域规模（`n_gullies`、`poly_perimeter_km`、`area_km2`）主导了预测，而**防治特征（`dam_number`、`has_dam`、`built_year`）重要性都很低**（≤0.037）。 逻辑回归中 `n_gullies` 系数最大（+1.95），即**支沟越多的流域越易发**——符合"物源供给面积大"的直觉。

> **位置特征的解释要克制。** `centroid_lat` 重要性最高，但它很可能只是 **“离震中 / 发震断层的距离”的代理变量**，而不是因果驱动因素。 本文不把它解读为”纬度越高越危险”。

---

8. 震后时效与工程防治

8.1 触发雨量随年份的变化

年份	触发行数	事件数	平均历时 h	平均总雨量 mm	平均 max1h mm	平均雨强 mm/h
2008	10	10	13.4	18.7	4.2	1.11
2009	4	4	23.5	26.9	9.5	1.24
2010	230	79	15.9	63.3	18.8	4.52
2011	45	21	18.0	47.3	13.0	2.84
2012	2	1	12.5	79.7	37.9	8.17
2013	130	15	52.6	221.1	18.4	4.31
2016	8	1	35.0	91.5	14.3	2.56
2019	14	12	36.7	181.3	24.6	4.82
2020	1	1	59.0	344.7	32.6	5.84

不做”阈值恢复”的结论。 表中可见 2008–2009 年触发雨量很小（平均总雨量 18.7 / 26.9 mm），2010 年后明显抬升（63.3 → 221.1 → 181.3 → 344.7 mm），**方向与”震后阈值随时间恢复”一致。** 但：

1. 每年样本量极度不均（2010 年 230 行 vs 2020 年 1 行）；
2. 触发雨量的大小还取决于**当年下了什么雨**，不是纯粹的阈值指标；
3. 要把”阈值恢复”做成结论，需要**同年内”触发 / 非触发”对比**而非跨年比较均值。

因此本文**只描述现象，不做因果断言**。这是与 C7 一致的态度。

8.2 工程防治与事件数：选址偏差

坝数	流域数	事件数	平均事件数	高易发流域
0	56	105	**1.88**	20/56
1	9	25	2.78	4/9
2	3	9	3.00	3/3
≥3	11	28	2.55	8/11

建成年	流域数	事件数	平均事件数
无记录	57	122	2.14
2011	6	9	1.50
2012	1	3	3.00
2013	12	19	1.58
2014	2	10	5.00
2018	1	4	4.00

prevented	流域数	事件数	平均事件数
False	62	134	2.16
True	17	33	1.94

结论：这批数据无法用来评估拦砂坝的防治效果。 有坝流域平均事件数（2.55–3.00）是**无坝流域（1.88）的 1.4–1.6 倍**。 这不是”坝导致了泥石流”，而是**选址偏差**：坝被建在历史上灾害更频发、威胁更大的流域。同向证据：`corr(area, has_dam) = 0.5133`（大流域更可能有坝），而 `corr(area, n_events) = -0.0175`（面积与事件数几乎无关）—— 说明有坝流域的”较高事件数”不能由面积解释。

另外，`prevented=True` 的流域平均事件数（1.94）反而**低于** `prevented=False`（2.16），但这个差值（0.22 次）在 79 个流域的样本量下**不构成证据**，不做解读。

正确做法（本数据不支持，故不实施）：需要**事件前后对比**（坝建成时间已知，可做 interrupted time series 或 before/after 对照），而不是横截面比较。 本数据集提供了 `built_year`，理论上可做，但建成年高度集中在 2011–2014，且坝建成后的观测年份太少，**功效不足以支撑结论**。

---

9. 差异分析与局限

项	原文声明	本次复现	说明
事件数	186	186	一致
流域数	79	79	一致
雨量站数	89	39（按文件名编号去重）	**口径差异**：原文 89 指覆盖 1566 km² 的全部站，本数据集只随事件打包了其中的子集
研究区面积	892 km²	851.0 km²（79 多边形之和）	−4.6%，口径差异
降雨阈值	**未报告**	6 条经验曲线 + 5 个 ML 模型	原文为数据论文，无此内容
易发性	**未报告**	5 个模型，AUC 0.78–0.82	原文为数据论文，无此内容

主要局限

1. **样本独立性**：Task A 的 1597 行来自 146 个事件文件夹，事件内相关性无法完全消除， `GroupKFold` 只是缓解。真要做预警系统，应按**流域**或**年份**做外层分组。
2. **时间不平衡**：2010 年占 52.7% 的事件，模型很可能在学”2010 年的雨”。
3. **temporal 协议不可用**：≥2016 只有 57 行。
4. **易发性标签是相对的**： `n_events > median` 只是把流域分成两半， 不代表物理意义上的”易发/不易发”；换个切分点结论会变。
5. **无 DEM**：缺少坡度、高程、沟道比降等真正控制泥石流的地形因子， 是 Task B 信号弱的最可能原因。
6. **工程防治不可评估**：见 8.2 节，横截面数据存在选址偏差。
7. **未做阈值的不确定性量化**：I–D 曲线只给了点估计，没有置信带。
8. **正样本标注依赖日历日**：95 条事件无时刻，触发判定用整日窗口， 7/444 的正样本退化为”当天之前最后一场雨”。

与文献阈值的关系

本文**刻意不把未核验的文献系数当基线**。此前调研中出现的若干汶川震区 I–D 系数 （如 Guo 2016、Tang 2012、Zhou & Tang 2014、Jiang 2021 等）， 当时只能取到搜索结果标题与链接、**无法取得全文核验**，因此**一律不作为定量对照**。本项目报告的所有阈值系数**均由本次数据自行拟合**， 可完整复算。若后续取得全文，可在同一评分口径下补充对比。

---

10. 复现说明

10.1 一键复现

```
python -m venv .venv
.\.venv\Scripts\python.exe -m pip install -r requirements.txt
.\.venv\Scripts\python.exe run_all.py
```

`run_all.py` 顺序执行 5 个阶段：

阶段	脚本	输出
1	`scripts/build_interim.py`	`data/interim/*.csv`、`data/processed/rain_events_raw.csv`
2	`scripts/build_catchment_features.py`	`data/processed/catchment_features.csv`
3	`scripts/run_models.py`	`results/metrics_summary.csv`、两个 JSON
4	`scripts/make_figures.py`	`results/figures/*.png`
5	`scripts/verify_results.py`	对 `results/repro_manifest.json` 逐个 SHA-256 校验

10.2 随机性与确定性

- **固定种子**：`SEED = 20220901`（`scripts/run_models.py`）与 `SPLIT_SEED = 20220901`（`src/wenchuan/models.py`）。
- 所有 estimator 的 `random_state`、所有 CV 的 `random_state` 都由该种子派生；`n_jobs=1` 以避免并行导致的浮点归约顺序差异。
- **逐字节可复现已实测验证**：连续两次运行 `run_all.py`（第二次含完整校验），16 个产物全部通过 SHA-256 比对，输出 `OK: every artefact reproduces bit-for-bit.` 完整日志见 `results/run_all_stdout.txt` 与 `results/repro_run2.log`。
- 单次全流程运行时间约 **52–63 秒**（Windows 11，CPU）。

10.3 关键参数汇总

参数	值	位置
随机种子	20220901	`run_models.py`, `models.py`
湿小时阈值	0.1 mm	`features.py` `WET_MM`
场次切分干间隔	6 h	`features.py` `DRY_GAP_H`
场次最小总雨量	1.0 mm	`features.py` `MIN_TOTAL_MM`
API 衰减系数	0.9 /h	`features.py` `API_K`
I–D 窗长	1,3,6,12,24,48,72 h	`threshold.py` `WINDOWS`
Task A 随机划分	7:3 分层	`run_models.py`
Task A 主协议	`GroupKFold(5)` on `DF_ID`	`run_models.py`
Task A 时间划分	训练 ≤2013 / 测试 ≥2016	`run_models.py`
Task B 评测	`RepeatedStratifiedKFold(5×10)`	`run_models.py`
随机森林	500 棵, `min_samples_leaf=2`	`models.py`
XGBoost	400 棵, depth 4, lr 0.05	`models.py`

10.4 产物清单

文件	内容
`results/metrics_summary.csv`	全部模型的 acc / prec / rec / F1 / AUC / 混淆矩阵（27 行）
`results/task_a_rainfall_threshold.json`	Task A 全量结果：三协议、6 条 I–D 曲线、特征重要性、逐年雨量
`results/task_b_susceptibility.json`	Task B 全量结果：CV 均值/标准差、OOF、特征重要性、79 流域明细
`results/figures/fig01..07*.png`	7 张图
`results/repro_manifest.json`	16 个产物的 SHA-256
`results/run_all_stdout.txt`	首次全流程日志
`results/repro_run2.log`	第二次全流程 + 复现校验日志
`docs/_numbers.md`	报告引用数字的自动汇总（由 `scripts/explore/report_numbers.py` 生成，可重算）

所有图的数字都能在 CSV/JSON 中查到，报告不依赖读图。

10.5 环境

Windows 11 x64，Python 3.12.10，pandas 3.0.6 / numpy 2.5.3 / scikit-learn 1.9.1 / matplotlib 3.11.2 / seaborn 0.13.2 / xgboost 3.4.1。**CPU 即可，无 GPU，无深度学习。** `src/wenchuan/geometry.py` 与 `dbf.py` 是手写的 SHP/DBF 读取器，**刻意不依赖 geopandas / GDAL / fiona**，避免复现时卡在二进制依赖上。

生成 `docs/report.pdf` 需要 `pandoc` + 无头 Edge/Chrome：

```
.\.venv\Scripts\python.exe scripts\build_report.py
```

10.6 来源、改动点与已更正的错误

本仓库代码**全部自行编写，未复制任何外部开源实现**。借鉴的是方法学惯例：

- `I = a·D^(-b)` 幂律形式来自 Caine (1980)（本领域通行形式）；
- 固定窗长最大雨量构造 (D, I) 对，是降雨阈值研究的标准做法；
- `GroupKFold` 按事件分组防泄漏、以中位数切分易发性标签，均为通行做法。

已更正的错误（保留记录以免误导后续读者）：

位置	原值	实测更正
本报告早期草稿 C4	OLS r^2 = 0.0200 / 0.0197	**0.3503 / 0.4855**
本报告早期草稿 C4	分位数 r^2 = 0.9204	**0.9909 / 0.9649 / 0.9911**
本报告早期草稿 C2	前三特征 duration/total/n_wet	**n_wet_hours / duration_h / max_24h**
本报告早期草稿 C6	有坝流域事件数 3.3–4.5 倍	**1.4–1.6 倍**
`make_figures.py` 图 1 标题	"r = 0.01"	改为运行时计算（实测 **0.274**）
`threshold.py` 文档字符串	"Pearson r = −0.08"	实测 **+0.274**（见 §6.1）
`README.md` §6	"1597 行 / 439 正样本"	**444 正样本**

附录 A：图表清单

图	文件	内容
图 1	`fig01_id_scatter.png`	湿 spell 定义的 (D, I) 散点（标题内嵌实测 r）
图 2	`fig02_id_windows.png`	固定窗长 (D, I) 点云 + 拟合曲线（ML 等效曲线缺失，见 §6.4）
图 3	`fig03_events_by_year.png`	逐年事件数与触发雨量强度
图 4	`fig04_task_a_models.png`	Task A 三协议下各模型 accuracy / F1
图 5	`fig05_confusion.png`	Task A、Task B 混淆矩阵
图 6	`fig06_feature_importance.png`	两个任务的特征重要性
图 7	`fig07_susceptibility.png`	事件数分布、面积-事件散点、坝数-事件柱状

附录 B：数据引用

Wang L., Chang M., Le J., Xiang L., Ni Z. (2022). *Two multi-temporal datasets to track debris flow after the 2008 Wenchuan earthquake.* Scientific Data 9:525. doi:10.1038/s41597-022-01658-y。 数据：doi:10.5281/zenodo.6891244（CC BY 4.0）。 数据集基于 Fan et al. (2019) 更新而来。